

Système d'ingestion de données environnementales "ecosense"

1. Le scénario métier

La métropole connectée "EcoSense" déploie des milliers de capteurs environnementaux IoT pour mesurer en temps réel la qualité de l'air, l'indice sonore et le taux d'humidité des quartiers. Ces capteurs envoient un flux ininterrompu de données métriques. Le défi est double :

1. Certaines données critiques (ex: pic de pollution extrême ou incendie suspect) doivent être détectées et traitées instantanément pour alerter les services d'urgence.
2. L'intégralité des données brutes normales doit être stockée de manière asynchrone pour permettre aux équipes de data science de générer des rapports statistiques hebdomadaires.

Votre équipe DevOps doit concevoir une infrastructure hautement résiliente, capable d'absorber des pics d'envoi massifs sans jamais saturer les systèmes de calcul ni perdre un seul message, même si une région AWS complète devient indisponible.

2. L'application de départ

Pour ce projet, la génération des données est simulée :

- Un script de simulation s'exécute localement et émule le comportement de 500 capteurs IoT envoyant simultanément des payloads JSON (ex: `{"sensor_id": "S-99", "metric": "CO2", "value": 450, "status": "CRITICAL"}`).
- Les codes des fonctions de traitement (scripts Python ou Node.js légers) vous sont également fournis. Ils lisent les messages, les analysent et les trient.

3. Exigences techniques (région principale : `us-east-1`)

L'intégralité de l'infrastructure de collecte et de traitement doit être automatisée via AWS CloudFormation ou AWS CDK.

Couche d'ingestion et fan-out pattern

- **Amazon SNS (Simple Notification Service)** : Création d'un Topic SNS public servant de point d'entrée unique pour la publication des données des capteurs.
- **Amazon SQS (Simple Queue Service)** : Création de deux files d'attente distinctes, toutes deux abonnées au Topic SNS principal :
- **File 1 (Alert-Queue)** : Dédiée aux urgences. Vous devez configurer une politique de filtrage de message (Subscription Filter Policy) sur SNS pour que seuls les messages contenant l'attribut `status: "CRITICAL"` y soient acheminés.
- **File 2 (Archiving-Queue)** : Dédiée au stockage de masse. Elle reçoit 100% du flux de données, sans filtre, pour traitement ultérieur.

Couche de traitement (calcul serverless)

- **AWS Lambda** : Déploiement de deux fonctions de traitement distinctes, déclenchées par les files SQS (Event Source Mapping) :

- **Lambda Alert-Processor** : Se déclenche immédiatement dès qu'un message arrive dans la file `Alert-Queue` afin d'exécuter une action immédiate (écriture de log d'urgence ou re-notification).
- **Lambda Archiving-Processor** : Se déclenche sur la file `Archiving-Queue` en mode "Batch" (par lots de 10 ou 20 messages) pour regrouper les données et optimiser les performances d'écriture.

Couche Stockage (Persistance)

- **Amazon Simple Storage Service (S3)** : Un bucket sécurisé dans lequel la fonction Lambda `Archiving-Processor` va déposer les lots de métriques consolidés sous forme de fichiers `.json` ou `.csv`.

Couche visualisation

- **Amazon Athena** : Créez une table externe pointant sur le bucket S3 et exécutez des requêtes SQL pour extraire des statistiques.
- **Amazon QuickSight** : Si l'outil est disponible avec AWS Academy, utilisez-le pour générer des dashboards de business intelligence.

4. Le défi multi-région

En cas de panne générale de l'infrastructure de messagerie ou de calcul dans la région `us-east-1`, le flux de capteurs ne doit pas être interrompu.

Stratégie de résilience à implémenter :

1. **laC Multi-Région** : Votre code laC doit pouvoir instancier l'intégralité de la chaîne à l'identique dans la région de secours `us-west-2`.
2. **Réplication des Archives** : Mettez en place la réplication inter-région (Cross-Region Replication) sur le bucket S3 pour garantir que les données déjà archivées en `us-east-1` soient dupliquées en temps réel vers le bucket de secours en `us-west-2`.
3. **Plan de basculement**

5. Scénario de Crash-Test Attendu

Lors de l'évaluation finale devant le jury, l'infrastructure subira les validations suivantes :

- **Test 1 (Lissage de charge et filtrage)** : Vous lancerez le simulateur à pleine puissance. Vérifiez que les messages normaux vont uniquement dans la file d'archivage, et que l'apparition d'un message critique déclenche instantanément la file d'alerte. Observez l'efficacité du tampon SQS pour prouver qu'aucune donnée n'est perdue même en cas de fort trafic.
- **Test 2 (Rupture régionale)** : Simulez la perte de la région principale `us-east-1`. Vous activerez le mécanisme de basculement sur le script de simulation. Le jury vérifiera en direct que les données environnementales continuent d'être ingérées, traitées et stockées en toute sécurité dans la région `us-west-2`.